

AI개발 수행내역서

항목	내용
----	----

과제명	AI 기반 베어링 예지보전 시스템 개발 — 진동 데이터를 활용한 리니어 모션 부품 열화 진단
-----	---

담당자	강두훈
-----	-----

작성일	2026년 6월 24일
-----	--------------

AI개발 수행내용

1. 사업과제

○ 진동 데이터를 활용하여 리니어 모션 핵심부품(베어링·구름요소)의 열화 상태를 조기에 진단하는 AI 기반 예지보전(Predictive Maintenance) 모델 및 웹 기반 진단 시스템 개발

2. 개요 및 현황

2.1 추진배경 및 목적

○ 반도체·디스플레이·배터리 등 첨단 제조 산업에서는 생산설비의 ****가동률(uptime)****이 곧 경쟁력이며, 설비를 구성하는 리니어 모션 부품(리니어 가이드, 볼스크류, 베어링 등)은 정밀 이송을 담당하는 핵심 요소이다. 이들 부품이 마모·열화될 경우 설비 정지뿐 아니라 가공 정밀도 저하에 따른 품질 불량으로 직결된다.

○ 특히 반도체 전공정 장비는 비계획 정지(unplanned downtime) 1회당 막대한 손실이 발생하므로, 고장이 발생한 뒤 부품을 교체하는 ****사후정비(reactive maintenance)****나 일정 주기마다 무조건 교체하는 ****예방정비(preventive maintenance)****의 한계가 크다. 이에 따라 설비의 실제 상태를 측정하여 고장 이전에 정비를 수행하는 ****상태기반 예지보전(condition-based predictive maintenance)****에 대한 수요가 급증하고 있다.

○ 베어링 및 구름요소의 대표적 고장 모드는 볼-궤도(raceway) 간 **구름접촉 피로(rolling-contact fatigue)**에 의한 **마모**이며, 이러한 초기 열화는 부품이 완전히 고장 나기 이전에 **진동 신호(특히 RMS)의 점진적 상승**으로 선행하여 나타난다. 따라서 진동 데이터를 분석하면 부품의 열화 상태를 사전에 감지할 수 있다.

○ 글로벌 자동화 선도기업(보쉬 렉스로스 등)은 리니어 가이드 하드웨어에 온도·모션 센서를 내장한 통합측정시스템(IMS)을 적용하고, 머신러닝 기반 상태진단 서비스(ODiN, Online Diagnostic Network)를 통해 비계획 정지를 계획정비로 전환하는 방향으로 제품을 고도화하고 있다. 이에 데이터 기반 예지보전 분석 역량의 확보가 요구된다.

- 본 과제는 공개된 베어링 가속수명시험 진동 데이터를 활용하여 베어링의 **정상/열화 상태를 분류**하는 AI 모델을 구축하고, 이를 웹 기반 진단 시스템(프로토타입)으로 구현함으로써, 현장의 **비계획 정지를 계획정비로 전환**하는 의사결정 근거를 제공하는 것을 목적으로 한다.
- (목적 요약)
 - 진동 특성과 베어링 열화 상태 간의 관계 규명 및 핵심 변수 식별
 - 정상/열화를 판정하는 고신뢰 분류 모델 구축 및 성능 최적화
 - 진단 결과를 직관적으로 확인할 수 있는 웹 기반 예지보전 프로토타입 구현
 - 동일 방법론을 볼스크류·리니어 가이드 등 타 구름요소 부품으로 확장할 수 있는 기반 마련

2.2 과제 범위

과제구분	내용
데이터 수집	베어링 가속수명시험(run-to-failure) 진동 원시 데이터 확보 및 데이터셋 구축
데이터 전처리·특성추출	진동 원신호로부터 시간영역 특성(RMS·첨도·왜도·파고율) 추출
라벨 정의	베어링별 초기 정상상태 RMS 대비 임계 배수를 기준으로 정상/열화 라벨 생성
탐색적 데이터 분석	열화 곡선 분석, 상관관계·다중공선성 진단(heatmap) 및 핵심 특성 선정
모델 선정·학습	로지스틱회귀·결정트리·랜덤포레스트 분류 모델 비교 및 선정
성능 평가	시간순 분할(slice) 검증 기반 정확도·정밀도·재현율·F1·혼동행렬 평가
모델 최적화	GridSearchCV(GroupKFold) 기반 하이퍼파라미터 최적화
프로토타입 구축	Streamlit 기반 예지보전 진단 대시보드 구현
시각화·테스트	열화 곡선·중요도·혼동행렬 시각화 및 통합 테스트

2.3 과제 추진 방법

1) 구축 대상 선정 기준

- 데이터 접근성 및 신뢰성
 - 정상부터 고장까지 전 생애(run-to-failure)가 기록되어 열화 라벨링이 가능한 공개 데이터셋 확보 가능 여부
 - 학술적으로 검증되고 측정 조건이 명확히 공개된 신뢰성 있는 데이터 사용 여부
- 변수 통제 및 문제의 명확성
 - 운전조건(회전속도·하중)에 따른 진동 특성 차이가 결과를 교란하지 않도록, 단일 운전조건(35Hz·12kN)으로 한정하여 변수를 통제

- "정상/열화"라는 목표 변수가 명확하고 측정 가능하며, 진동 특성을 독립변수로 하는 분류 모델링이 가능
- 확장성 및 산업적 기여
 - 동일 방법론을 볼스크류·리니어 가이드 등 타 구름요소 부품의 상태진단으로 확장 적용 가능
 - 비계획 정지 비용 절감 및 계획정비 전환을 통한 설비 운영 효율 제고에 기여

2) AI 예측 분석모델 적용 대상

대상기능	수집 데이터	예측모델인자(독립변수)	AI예측 분석 대상
베어링 상태 진단을 통한 예지보전	베어링 가속수명시험 진동 데이터(수평·수직)	진동 시간영역 특성: RMS, 첨도, 왜도, 파고율	정상/열화 상태 분류 및 열화 조기 경보

3) 분석모델 구축 프로세스

◦ 진동 원시 데이터 수집 → 시간영역 특성 추출(데이터 압축) → 베어링별 초기 기준 대비 임계 배수로 정상/열화 라벨링 → 탐색적 데이터 분석(열화 곡선·다중공선성)을 통한 핵심 특성 선정 → 분류 모델 비교 및 선정 → GridSearchCV 최적화 → 웹 기반 진단 시스템(프로토타입) 구축의 순서로 진행한다.

연구개발 주요 결과물

1. 데이터 수집

가. 데이터 출처

◦ XJTU-SY 베어링 가속수명시험 데이터셋 (중국 시안교통대학교 + Changxing Sumyoung Tech 공동 제작, 공개 데이터)

나. 데이터 개요

- 본 데이터셋은 15개 구름베어링을 3가지 운전조건에서 정상부터 고장까지 측정한 가속수명시험 데이터이며, 본 과제에서는 변수 통제를 위해 단일 운전조건(35Hz·12kN, 베어링 5개)을 사용하였다.
- 측정 사양: 베어링 하우징에 수평·수직 2개의 가속도계를 직교 배치하여 25.6kHz로 측정하며, 1분마다 1.28초(32,768 포인트)의 진동 스냅샷을 기록한다. 각 스냅샷은 CSV 형태로 저장되어 있다.

베어링	총수명(분)	측정 신호
Bearing1	123	수평/수직 진동
Bearing2	161	수평/수직 진동
Bearing3	158	수평/수직 진동
Bearing4	122	수평/수직 진동
Bearing5	52	수평/수직 진동

○ 진동 스냅샷을 특성으로 압축한 결과 유효 관측치는 총 616개(행)이며, 결측치는 존재하지 않는다.

2. 데이터 전처리 및 특성 분석

가. 특성 추출

○ 진동 원신호는 1개 스냅샷당 32,768개의 값으로 구성되어 직접 학습에 활용하기 어렵다. 이에 각 스냅샷을 **시간영역 통계 특성**으로 압축하여 1개 스냅샷을 1개 행으로 변환하였다. 주파수 변환(FFT)은 사용하지 않고, 베어링 진단에서 널리 활용되는 시간영역 특성만을 사용하였다.

특성	정의	의미
RMS(제곱평균제곱근)	$\sqrt{(\text{신호 제곱의 평균})}$	진동의 유효 크기. 마모 진행 시 상승하는 열화 핵심 지표
첨도(kurtosis)	분포의 뾰족함 정도	날카로운 충격 성분에 민감하여 초기 결함 감지에 유리
왜도(skewness)	분포의 비대칭(치우침) 정도	진동 분포의 한쪽 쓸림을 표현
파고율(crest factor)	$\text{최대값} \div \text{RMS}$	전반적 크기 대비 순간 스파이크의 비율

○ 수평·수직 신호 각각에 대해 위 특성을 추출하였다.

나. 열화 라벨 생성

○ 본 과제는 회귀(정확한 잔여수명 예측)가 아니라, 현업의 임계값 알람 방식과 동일한 **정상/열화 이진 분류**로 문제를 정의하였다. 현업에서는 베어링을 완전히 고장날 때까지 사용하지 않고, 열화 징후가 나타나면 계획정비 시점에 교체하기 때문이다.

○ 라벨 기준: 각 베어링의 초기 정상상태(최초 10분) RMS 평균의 **2.5배**를 임계값으로 설정하고, 해당 시점 RMS가 임계값을 초과하면 열화(1), 그렇지 않으면 정상(0)으로 라벨링하였다. (임계 배수

2.5는 열화 곡선상 평탄 구간의 노이즈를 정상으로 두면서 급상승 초입을 포착하는 균형점으로 선정)

○라벨 분포: 정상(0) 411개 / 열화(1) 205개

다. 탐색적 데이터 분석

○ 열화 곡선(베어링별 RMS 추이): 모든 베어링에서 정상 구간에는 RMS가 평탄하게 유지되다가, 열화가 시작되면 RMS가 급격히 상승하는 패턴이 공통적으로 관찰되었다. 이는 "진동으로 열화를 감지할 수 있다"는 본 과제의 가설을 뒷받침한다. (※ [그림] fig_rms.png 삽입)

○ 다중공선성 분석: 전체 진동 특성(수평·수직 14종)의 상관관계를 분석한 결과, 크기 계열 특성(평균절대값·표준편차·RMS·최대값)이 수평·수직 모두 0.9 이상으로 강한 다중공선성을 보였다. 또한 첨도는 수평·수직 간 상관이 0.96으로 사실상 동일한 정보를 담고 있었다. (※ [그림] 전체 상관관계 heatmap 삽입)

○ 핵심 특성 선정: 다중공선성이 확인된 크기 계열은 대표값으로 **RMS** 하나만 채택하고, 수평·수직 중복은 수평(h_)으로 통일하였다. 최종적으로 상호 상관이 낮아(최대 0.52) 서로 독립적인 4개 특성 — **RMS(크기)·첨도(뽀죽함)·왜도(치우침)·파고율(스파이크 비율)** — 을 선정하였다. (※ [그림] fig_corr.png 삽입)

라. 시계열 데이터의 분할 방식

○ 본 데이터는 베어링의 시간순 생애 데이터(시계열)이므로, 데이터를 무작위로 섞는 train_test_split을 사용할 경우 동일 베어링의 미래 시점 정보가 과거 학습에 유입되는 데이터 누수가 발생한다. 이를 방지하기 위해, 시간순으로 데이터를 분할(slice)하여 **각 베어링 생애의 전반부(0~75%)를 학습, 후반부(75~100%)를 평가에 사용하였다.** (학습 459행 / 평가 157행)

3. 데이터 학습 및 모델 정의

가. 모델 비교

○ 복잡도가 점증하는 3종의 분류 모델을 비교하였다. 로지스틱회귀는 스케일에 민감하여 StandardScaler를 적용하였고, 트리 계열(결정트리·랜덤포레스트)은 분할 기준 특성상 스케일링이 불필요하여 적용하지 않았다.

모델	정확도	정밀도	재현율	F1
로지스틱회귀	0.885	0.991	0.865	0.924
결정트리	0.955	0.992	0.952	0.972
랜덤포레스트	0.994	0.992	1.000	0.996

○ 평가지표 선정 사유: 본 과제는 "실제 열화를 놓치지 않는 것"이 가장 중요하므로(놓침은 곧 설비 정지로 직결), 정확도뿐 아니라 ****재현율(recall)****을 핵심 지표로 함께 고려하였다.

나. 모델 선정

○ 결론: 단순한 로지스틱회귀는 비선형 열화 패턴을 충분히 포착하지 못하였고, 단일 결정트리는 과 적합 위험이 있었다. 반면 다수의 트리를 앙상블하는 **랜덤포레스트 (RandomForestClassifier)**가 재현율 1.000, F1 0.996으로 가장 우수하고 안정적이어서 최종 모델로 선정하였다.

다. 변수 중요도

○ 랜덤포레스트의 변수 중요도 분석 결과, RMS가 약 0.817(82%)로 압도적이어서 열화 판정의 핵심 지표임이 정량적으로 확인되었다. 왜도(0.115)가 그다음으로, 다른 특성과 겹치지 않는 독립적 정보를 보조적으로 제공하였으며, 파고율(0.046)·침도(0.022)가 경계 구간 분류를 보조하였다. (※ [그림] fig_importance.png 삽입)

라. 모델 최적화

○ GridSearchCV를 통해 랜덤포레스트의 하이퍼파라미터를 탐색하였다. 검증 폴드 또한 데이터 누수를 방지하기 위해 베어링 단위(GroupKFold)로 구성하였다.

하이퍼파라미터	탐색값
n_estimators	100, 200, 300
max_depth	None, 5, 10
min_samples_split	2, 5, 10
min_samples_leaf	1, 2, 4

○ 최적 파라미터: n_estimators=100, max_depth=None, min_samples_split=2, min_samples_leaf=1 (교차검증 F1 0.926). 최적 조합이 기본값으로 선정된 것은, 선정한 4개 특성이 분류 경계를 충분히 잘 설명하여 모델 복잡도 조정의 추가 이득이 작음을 의미한다.

4. 결과 시각화 및 성능 평가

○ 최종 모델(랜덤포레스트)을 시간순 분할 평가에 적용한 결과는 다음과 같다.

지표	값
정확도(Accuracy)	0.994
정밀도(Precision)	0.992
재현율(Recall)	1.000
F1-score	0.996

○ 혼동행렬(Confusion Matrix): 실제 열화 126건을 전부 정확히 탐지하였으며(미탐지 0건), 정상 31건 중 1건만 열화로 오판(거짓경보)하였다. 즉 "열화를 놓치지 않는다"는 예지보전의 핵심 요건을 충족하였다. (※ [그림] fig_cm.png 삽입)

실제\예측	정상(0)	열화(1)
정상(0)	30	1
열화(1)	0	126

5. 프로토타입 (웹 기반 진단 시스템)

- Streamlit 기반의 예지보전 진단 대시보드를 구현하였다. 비전문가도 이해할 수 있도록 부품 설명 페이지를 포함하였으며, 4개 탭으로 구성하였다.
- 설명: 베어링의 구조와 마모 원리, 진동 특성(RMS·첨도·왜도·파고율) 해설
 - 데이터 탐색: 베어링별 열화 곡선, 특성 간 상관관계
 - 모델 성능: 변수 중요도, 혼동행렬, 성능 지표
 - 열화 진단: 진동 특성 4종을 입력하면 정상/열화를 실시간 판정 (시연용)
- 학습된 모델은 joblib.pkl로 저장하여 앱에서 로드·예측하는 구조로 구현하였다. (※ [그림] 대시보드 화면 삽입)

6. 결론 및 향후 계획

가. 모델 개발 결과 요약

○ 진동 원신호를 시간영역 특성 4종으로 압축하고, 베어링 초기 상태 대비 임계 배수로 정상/열화를 정의하여 랜덤포레스트 분류 모델을 구축하였다. 시간순 분할이라는 엄격한 검증 방식에서도 재현율 1.000, F1 0.996의 우수한 성능을 달성하였으며, RMS가 열화 판정의 핵심 지표임을 정량적으로 확인하였다.

나. 실무 적용 방안

- 본 모델은 반도체·디스플레이·배터리 등 첨단 제조 설비의 리니어 모션 부품(베어링·볼스크류·리니어 가이드) 상태진단에 적용할 수 있다. 진동 데이터만으로 열화를 조기 감지하여 **비계획 정지를 계획정비로 전환**함으로써, 설비 가동률 제고와 정비 비용 절감 효과를 기대할 수 있다.
- 이는 글로벌 자동화 기업이 제공하는 센서 내장형 통합측정시스템(IMS) 및 머신러닝 기반 상태진단 서비스(ODiN)가 고객에게 제공하는 가치를, 데이터 분석으로 직접 구현·검증한 것에 해당한다.

다. 한계점 및 개선 방향

- 급사형 고장의 조기 경보 한계: 일부 베어링(예: Bearing4)은 사전 징후 없이 수명 말기에 급격히 고장나는 양상을 보였다. 이러한 급사형 고장은 진동 기반 분석만으로는 조기 경보가 어려우며, 이는 예지보전의 알려진 본질적 한계에 해당한다.
- 개체 차이 미반영: 본 모델은 절대 RMS 기반이므로 베어링 개체별 초기 상태 차이를 반영하지 못한다. 현업에서는 각 장비의 초기값을 기준선으로 등록하고 상대 변화율로 판정하는 방식이 더 정밀하며(글로벌 자동차 기업의 IMS가 개체별 기준선을 학습하는 방식), 향후 이를 반영할 필요가 있다.
- 데이터 확장: 본 과제는 단일 운전조건의 베어링 5개로 한정되었다. 향후 다수 베어링·다양한 운전 조건으로 데이터를 확장하면 범용성과 신뢰도를 높일 수 있다.
- 다중 센서 융합: 진동 외에 온도 등 추가 센서 데이터를 융합하면 진단 정확도를 더욱 향상시킬 수 있다.
- 잔여수명 예측으로의 확장: 본 과제는 정상/열화 분류에 집중하였으나, 향후 충분한 데이터가 확보되면 잔여수명(RUL)을 정량적으로 예측하는 회귀 모델로 확장할 수 있다.